

OPENCLASSROOMS - PROJET 5


**SEGMENTEZ DES
CLIENTS D'UN SITE
E-COMMERCE**

AGENDA

1. Contexte et objectif
2. Requêtes SQL
3. Feature engineering
4. Avantages inconvénients des modèles testés
5. Analyse des clusters du modèle retenu
6. Maintenance
7. Conclusion

INTRODUCTION

Contexte et objectif



CONTEXTE

- Entreprise brésilienne de vente sur marketplaces en ligne.
- Besoin de structuration de l'écosystème Data et d'amélioration de suivi client.
- Dashboard Customer Experience déjà en place, alimenté par SQL.
- Historique clients disponible : commandes, produits, satisfaction, localisation depuis 2017.

OBJECTIF

- Fournir une **segmentation client exploitable** par l'équipe Marketing.
- Comprendre les profils clients selon :
 - Comportement d'achat (RFM : Recence, Fréquence, Montant)
 - Satisfaction clients
 - Autres features pertinentes issues des données disponibles
- Proposer une **description actionnable des clusters** et recommandations pour le **contrat de maintenance**.



REQUÊTES SQL

DASHBOARD


ÉQUIPE CUSTOMER EXPERIENCE

Requête	Résultat
Commandes en retard (<3 mois)	322 commandes
Top vendeurs (>100 000 R\$)	17 vendeurs
Nouveaux vendeurs engagés	3 vendeurs (240b9776d844d37535668549a396af32 - 81f89e42267213cb94da7ddc301651da - D13e50eaa47b4cbe9eb81465865d8cfc)
Zones avec insatisfaction client	4 codes postaux (22753, 47 reviews – 22770, 37 reviews - 22793, 90 reviews, 21321, 36 reviews – 22780, 37 reviews)

FEATURE ENGINEERING

RFM

Review score



Recency Frequency Monetary

Agrégation au niveau commande

- Calcul du montant total de chaque commande (*price* + *frais de livraison*).

Enrichissement des commandes

- Association des commandes aux clients uniques et conversion des dates en format datetime.

Agrégation au niveau client – RFM

- *Frequency* : nombre de commandes par client
- *Monetary* : montant total dépensé par client
- *Last_order_date* : date de dernière commande

Calcul de la recency

- Nombre de jours depuis la dernière commande par rapport à la date de référence (max des commandes).

2 VERSIONS

Review score

Ajout du review_score moyen


- Moyenne des notes clients (*review_score*) par commande puis par client.

Nettoyage du review-score

- Suppression des clients sans *review_score* (0.75% de la table)

Table finale

- Fusion de toutes les informations → chaque client a *frequency*, *monetary*, *recency*, *review_score* pour alimenter le clustering.



+/- DES MODÈLES TESTÉS

K-means

Agglomerative clustering

DB SCAN

DBSCAN

Méthode qui regroupe les éléments selon leur densité.

Les zones où les points sont très proches forment des clusters, et les points isolés sont considérés comme du « bruit ». Il n'est pas nécessaire de fixer le nombre de groupes à l'avance.

POINTS FORTS

Détecte clients atypiques et outliers naturellement ; pas besoin de choisir le nombre de clusters

Ne segmente pas tous les clients ; sensible aux paramètres ; difficile à utiliser seul pour marketing

LIMITES

SILOUETTE (*cohérence interne*)

N/A → pas de silhouette

2 clusters (*1063 clients classés comme bruit*)

AGGLOMERATIVE CLUSTERING

Méthode qui crée des groupes en partant de chaque élément seul, puis en fusionnant progressivement les éléments ou groupes les plus proches jusqu'à former une hiérarchie de groupes.

On peut choisir à quel niveau de cette hiérarchie couper pour définir le nombre final de groupes.

POINTS FORTS

Profils extrêmes
clairement
identifiés ; lecture
intuitive des
clients

Plus lent à calculer
; moins adapté aux
très grandes bases
Échantillon de 5K
lignes dans notre
cas

LIMITES

SILOUETTE (*cohérence interne*)

0.627 → très bonne cohérence

5 clusters

K-MEANS

Méthode qui regroupe des éléments similaires en un nombre fixe de groupes.

L'algorithme place d'abord des « centres » provisoires et ajuste ces centres pour que chaque élément soit assigné au groupe le plus proche, jusqu'à ce que les groupes soient stables.

POINTS FORTS

Segmentation enrichie : identifie clients insatisfaits et top clients ; facile à utiliser pour marketing

Groupes moins bien séparés ; certains clusters très petits

LIMITES

SILOUETTE (*cohérence interne*)

0.418 → cohérence correcte mais groupes un peu mélangés



5 clusters

CLUSTERS

Nombre et stabilité
Interprétation



CHOIX DU NOMBRE DE CLUSTERS




Le choix de 5 clusters offre un bon équilibre entre qualité de segmentation et niveau de détail, avec une amélioration de la compacité des groupes sans complexifier excessivement le modèle.


STABILITÉ DES CLUSTERS

Stabilité des centroïdes - $k = 4$ (3 itérations)


Random state = 0



Random state = 21




Random state = 42



- distance moyenne ≈ 0.0014 $\rightarrow$ déplacements des centroïdes quasi nuls
- distance maximale ≈ 0.0118 $\rightarrow$ aucun cluster ne bouge fortement
- écart-type ≈ 0.0028 $\rightarrow$ stabilité homogène entre clusters

RÉPARTITION ET PROFIL MOYEN




3 — Récents et très satisfaits (44.0 %)
→ Clients récents et satisfaits, contribution modérée au chiffre d'affaires

2 — Anciens et satisfaits (33.1 %)
→ Clients anciens et satisfaits, faible valeur économique


0 — Peu satisfaits (17.6 %)
→ Segment à risque, nécessite actions correctives

4 — Actifs moyens (3.1 %)
→ Clients actifs, contribution moyenne au chiffre d'affaires


1 — Premium mais peu nombreux (2.2 %)
→ Clients à forte valeur potentielle, prioritaire pour fidélisation




DISTRIBUTIONS DES VARIABLES




Tous les clients passent peu de commandes (fréquence $\approx 1-2$), cluster 4 étant légèrement plus actif (fréquence ≈ 2)



Les clients sont répartis en anciens (recency élevée : clusters 2 et 0), récents (recency faible : cluster 3) et intermédiaires (clusters 1 et 4)




La plupart des clients dépensent peu, mais quelques clusters se distinguent par des montants très élevés (cluster 1) ou moyens (cluster 4)




Les avis varient de moyens à excellents : clusters 0 a des notes faibles, clusters 2 et 3 des notes très élevées, et clusters 1 et 4 des notes correctes à bonnes.

REGROUPEMENT DES CLIENTS SELON LES VARIABLES



1. **Recency / Monetary / Review_score** : Met en évidence les clients récents et gros dépensiers, ainsi que leur satisfaction.
2. **Frequency / Monetary / Review_score** : Visualise les clients réguliers par rapport à leurs dépenses et leur review_score.
3. **Recency / Monetary / Frequency** : Compare l'activité récente et la dépense par rapport à la fréquence des commandes.
4. **Frequency / Recency / Review_score** : Identifie les clients fréquents mais récents ou anciens, en lien avec leur satisfaction.
5. **Monetary / Frequency / Review_score** : Met en avant les gros dépensiers réguliers et leur review_score.
6. **Recency / Frequency / Monetary** : Visualise les clients dormants vs actifs selon fréquence et dépense.



MAINTENANCE

CHOIX DU NOMBRE DE CLUSTERS

- Modèle stable jusqu'à 4 semaines ($ARI > 0.86$).
- Baisse progressive de la qualité après 5 semaines.
- Seuil critique atteint vers 6 semaines ($ARI < 0.8$).
- Réentraînement recommandé autour de 6 semaines.

